Soppsjekk

Malene Øyberg Halvorsen, 30.10.2026

1: Skildr Problemet

SCOPE

Målet med maskinlæringsprosjektet er å lage ei nettside der ein brukar lett kan finne ut om soppen den ser på er giftig eller ikkje, berre ved hjelp av sentrale kjenneteikn. Prosjektet skal vise korleis maskinlæring kan brukast til å klassifisere data, og korleis ein slik modell kan gjerast tilgjengeleg gjennom eit brukarvenleg grensesnitt.
Soppar kan vere vanskeleg å skilje i ein del tilfelle. Ein giftig soppar kan likne ein etande, noko som kan få alvorlege konsekvensar viss konsumert. Det er i tillegg soppar som er so giftig at viss dei har vore borti ein etande, so vil den som er etande ikkje lenger vere konsumerbar. Det finst difor eit behov for informasjon og hjelpemiddel som kan gjere det enklare å forstå kva kjenneteikn som skil ulike soppar frå kvarandre.
I dag kan ein identifisere sopp ved å bruke soppbøker, nettsider, biletdatabasar og appar for soppidentifisering. Ein kan òg spørje personar med god kunnskap om sopp. Manuell identifisering går mellom anna ut på å undersøkje utsjånaden til soppen, farga på hatten, forma på stilken, lukta, skivene under hatten og andre karakteristiske eigenskapar. Dette krev kunnskap og erfaring, og enkelte kjenneteikn kan vere vanskelege å vurdere for ein nybyrjar. Maskinlæring kan difor vere ein aktuell løysing sidan ein modell kan læra samanhengar mellom kjenneteikn og kjende klassar frå eit datasett. I staden for at programmeraren lagar alle reglane sjølv, lærer modellen mønstra frå døme der svaret allereie er kjend. Når modellen har lært desse mønstra, kan han bruke dei til å klassifisere nye datapunkt.

METRICS

For å vurdera kor godt dette prosjektet fungerer, er det naudsynt å undersøkje både kvaliteten på maskinlæringsmodellen og korleis sjølve nettsida fungerer.
Den vitigaste maskinlæringsmålinga er accuracy. Den vis kor stor del av døma modellen klassifiserer rett. Viss modellen klassifiserer 100 sopp til dømes og 98 av dei gjev rett svar på data han blir testa på, er nøyaktigheita 98 prosent. Høg nøyaktigheit vis at modellen ofte gjev rett svar på det han blir testa på. I dette prosjektet er det viktig å hugse at høg nøyaktigheit på eit datasett ikkje automatisk tydar at modellen er trygg å bruke på sopp i naturen, sidan konsekvensane på tilfella som er feil er sopass store.
Eg brukar òg kryssvalidering for å undersøkje kor stabil modellen er. Ved femdelt kryssvalidering vert treningsdataa delte i fem delar. Modellen vert trena og evaluert fem gonger, slik at ulike delar av dataa vert brukte til validering. Gjennomsnittet av resultata gjev eit betre bilete av korleis modellen presterer på ulike delar av datasettet enn ei enkel måling åleine.
I tillegg er det relevant å undersøkje forvekslingsmatrisa, som vis kor mange soppar modellen klassifiserer rett og feil klasse. For eit problem med giftig og etande sopp er det særleg viktig å undersøkje om giftige soppar vert klassifisert som giftig.

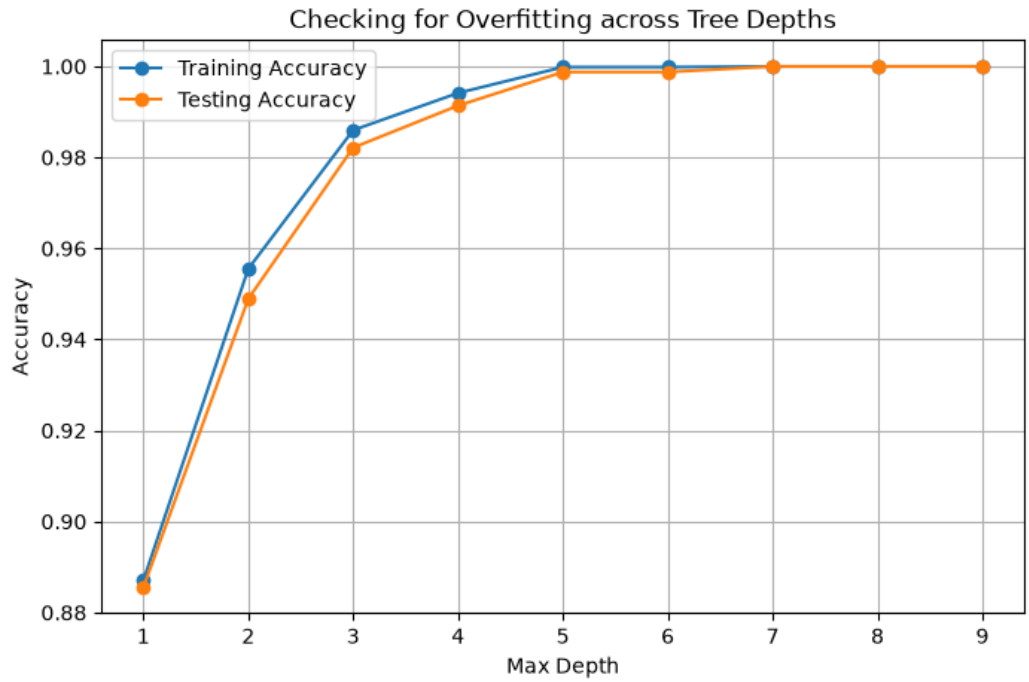
For nettsida er det relevant å undersøkje om brukarane kan velje alle naudsynte kjenneteikn, sende inn vala og få eit forståeleg resultat utan problem. Responstida bør òg vere kort, slik at brukaren slepp å vente lenge på ei føreseiing. I eit større prosjekt kunne ein målt brukarvenlegheit gjennom brukartestar og undersøkt kor ofte brukarar fullfører oppgåva utan hjelp.
For at dette prosjektet skal verte vellukka, bør modellen gje gode og stabile resultat på testdata, medan nettsida må fungere som planlagt. Sidan føremålet fyrst og fremst er å demonstrere maskinlæring, er det òg viktig at løysinga er enkel å forklare og at ein kan grunngje valet av modell.
Nettsida er fyrst og fremst meint som ein enkel demonstrasjon av korleis maskinlæring kan nyttast til soppklassifisering. Ho skal vere enkel å bruke, slik at personar utan kunnskap om programmering òg skal kunne prøve modellen.

2: DATA

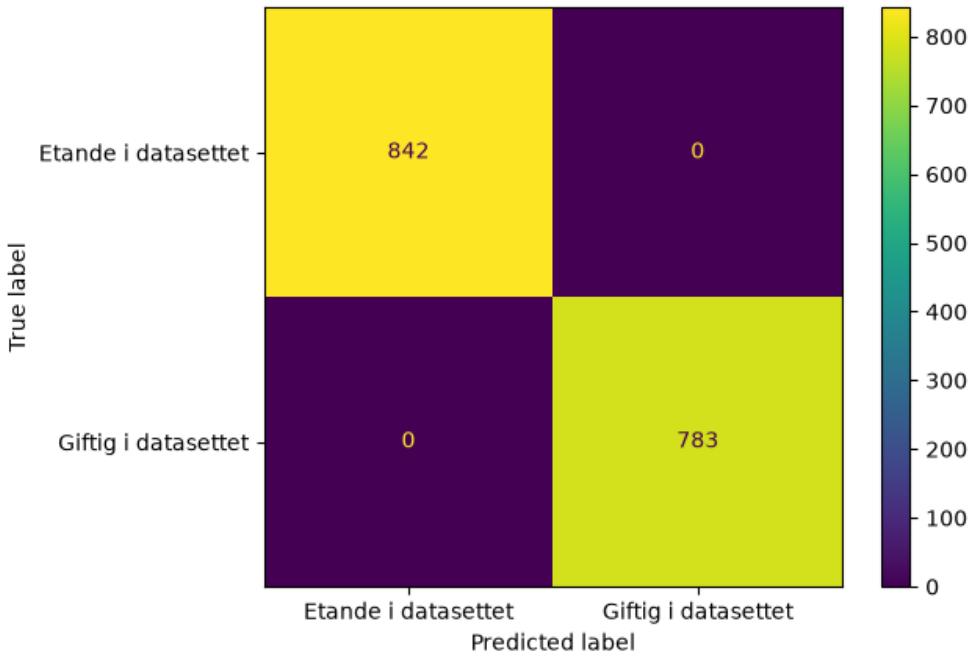
Datasettet som blir teken i bruk er Agaricus-Lepiota frå UC Irvine Machine Learning Repository (Mushroom, 1981). Det innheld registreringar av ulike soppar, der kvart datapunkt er skildra ved hjelp av fleire kjenneteikn. Datasettet har 22 kjenneteikn i tillegg til målvariabelen som vis kva klasse soppen høyrer til.
Målvariabelen er class, og har to verdiar: e (for edible) og p (for poisonous). Dette gjere datasettet eigna for ei binær klassifiseringsoppgåve, der målet er å føreseie kva av dei to klassane ein sopp høyrer til.
Kjenneteikna i datasettet er forma på hatten, overflata og farga på hatten, om soppen har merke, lukt, eigenskapar ved skivene under hatten, storleiken på skivene, med meir. Desse opplysingane er kategoriske, det vil seie at dei har ulike kategoriar og ikkje vanlege talmålingar. Sidan datasettet allereie inneheld både kjenneteikn og klassar, kan ein bruke «Supervised Learning». Modellen får døme der det rette svaret er kjend, og lærer samanhengar mellom kjenneteikna og klassa. Etter trening vert modellen testa på datapunkt den ikkje har nytta under sjølve treninga.
Før data vert nytta, vert dei lesne inn med pandas, og kolonnenamna vert lagde til manuelt. Verdiar som er merka med ?, vert erstatta med unknown, slik at ukjende opplysingar kan handsamast som ein eigen kategori.
Data vert delte inn i eit treningsett på 80 prosent og eit testsett på 2+ prosent. Treningssettet lærer modellen mønster i dataa, medan testsettet måler kor godt han klassifiserar nye døme.Ved å nytte stratify=y held eg delinga mellom klassane mest mogleg lik i begge setta.
Sidan kjenneteikna er kategoriske, nyttar eg OneHotEncoder til å lagje binære klonnar for dei ulike kategoriane. Dette gjere dataa eigna for maskinlæringsmodellen. Med handle_unknown= «ignore» kan modellen handsame kategoriar som ikkje finnast under treninga, utan at handsaminga gjort før stoppar.
I prosjektet testar eg alle dei 22 kjenneteikna, og andre kombinasjonar. Målet er å undersøkje om modellen kan nå gode resultat med færre opplysingar frå brukaren. Sidan dataa ikkje inneheld personopplysingar om brukarar, vil ikkje personvern vera noko stor utfordring. Sjølv om dette, bør ein vere open om at alle soppar i eksistens ikkje har vore med under treninga av datasettet.
Klassane i datasettet er allereie merka med om soppane er etande eller giftige. Dette gjev modellen kjende svar å lære frå under treninga. Ein føresetnad er at desse merkingane er at desse merkingane er rette, sidan feil i datasettet kan påverke kvaliteten på modellen.

3: MODELLERING

Eg starta med å prøve ut DecitionTreeClassifier, sidan boka seier at dette kan vere eit godt val når vi har med datasett som dette å gjere. Modellen passar godt til klassifisering med kategoriske kjenneteikn etter at dataa er handsama. Ein kan visualisera treet og enkelt sjå kva kjenneteikn som blir brukte, og i kva rekkjefylgje avgjerdene blir tekne. Dette gjere modellen godt eigna til eit prosjekt der eg ynskjer gode resultat, i tillegg til å kunne syne betre korleis modellen kjem fram til vala sine.
Eg nytta ein Pipeline for å samle handsaminga gjort på førehand og klassifiseringsmodellen i ei løysing. Fyrst vert dei kategoriske kjenneteikna handsama med OneHotEncoder, før dataa vert sende vidare til avgjerdstreet. Eg sette max_depth=7 for å avgrense kor djupt treet kan verte. Dette kan gjere treet enklare å lese og redusere risikoen for at modellen lærer for mange detaljar frå treningsdataa (overfitting). Eg nytta òg ein fast random_state for at forsøka skulle gje mest mogleg like resultat kvar gong.



For å undersøkje kor godt modellen presterte, nytta eg eit eige testsett og femdelt kryssvalidering på treningsdataa. Testsettet måler kor godt modellen klassifiserer data han ikkje har sett under treninga, medan kryssvalidering testar modellen på fleire delar av treningsdataa. Dette gjev eit betre utgangspunkt for å vurdere om avgjerdstreet faktisk lærer nyttige mønster frå dataa.
Eg undersøkte òg korleis ulike verdiar for max_depth påverka resultata. Eg testa djupnar frå 1 til 9 og samanlikna grannsemda til treningsdataa og testdataa. Dette gjorde det mogleg å sjå om modellen byrja å overtilpassa seg treningsdataa. Ut or resultata valde eg å nytte max_depth=7.
Eg nytta accuracy, precision, recall og F1-score for å vurdere resultata. Accuracy syner kor mange prediksjonar som var rette, medan dei andre måltala gjev meir informasjon om kor godt modellen klassifiserer kvar av dei to klassane. På testsettet fekk modellen 1.0 i accuracy, og kryssvalideringa gav eit gjennomsnitt på 99.97%. Forvekslingsmatrisa synte:



Figuren under syner resultata frå klassifiseringa på testsettet. Modellen fekk 1,00 i accuracy, precision, recall og F1-score for begge klassane (e og p). Testsettet inneheldt 1625 soppar, der 842 var etande og 783 var giftige. Modellen klassifiserte alle testdøma rett.

Accuracy: 1.0

	precision	recall	f1-score	support
e	1.00	1.00	1.00	842
p	1.00	1.00	1.00	783
accuracy			1.00	1625
macro avg	1.00	1.00	1.00	1625
weighted avg	1.00	1.00	1.00	1625

Til slutt samanlikna eg to avgjerdstre-modellar som eg fann ut gav best resultat i fylgje testinga: éin som brukte ni utvalde kjenneteikn, og éin som brukte alle dei 22 kjenneteikna i datasettet. Begge modellane fekk like gode resultat på testdataa og i kryssvalideringa, og ingen av dei klassifiserte testdataa gav feil. Avgjerdtrea var òg veldig like, med berre mindre skilnader nedst i trea. Dette tyder på at dei ni utvalde kjenneteikna inneheld tilstrekkeleg med informasjon til å oppnå like gode resultat som modellen med alle kjenneteikna. Eg valde difor å gå vidare med modellen med ni kjenneteikn, sidan han krev mindre informasjon frå brukaren.

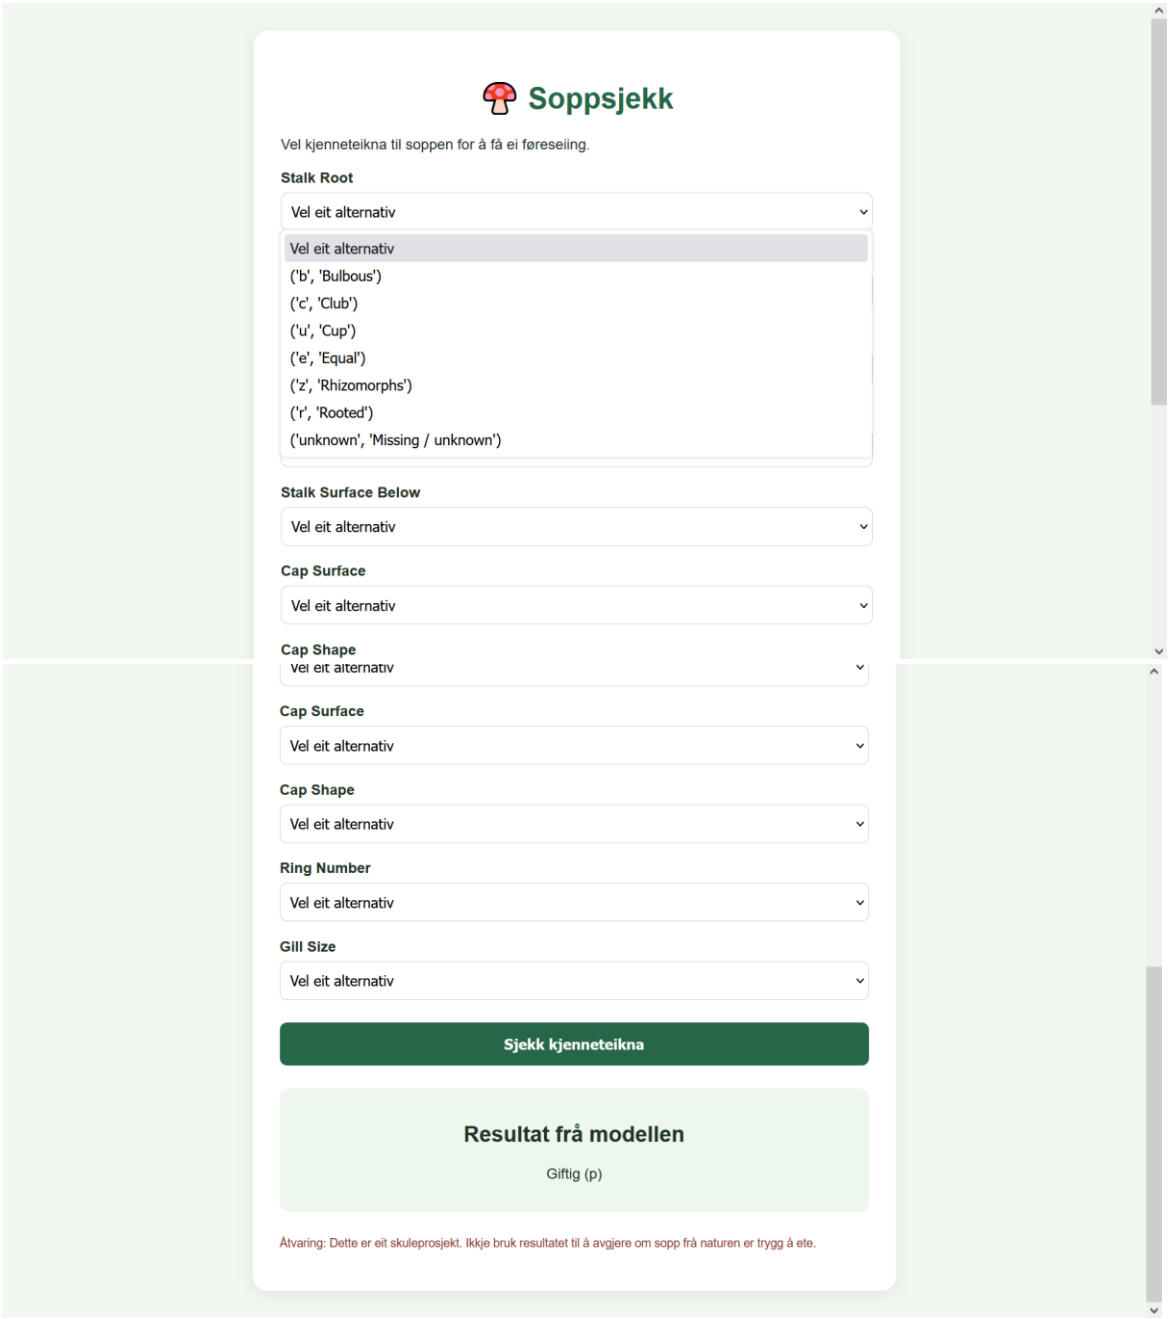


Resultata lyt likevel tolkast med varsemd. Ei nøyaktigheit på nesten 100 prosent på dette datasettet tyder ikkje på at modellen er feilfri i røynda. Testdataa kjem frå same datasett som treningsdataa og representerer ikkje alle soppar ein kan finne i naturen. Modellen er difor

meint som ei utprøving, og ikkje som eit trygt hjelpemiddel for å avgjere om ein sopp kan etast.

4: DEPLOYMENT

Vidare skulle eg utvikle ei nettside som skulle passe til modellen eg gjekk for. Nettsida har fleire delar. Fyrst har vi kjenneteikna brukaren lyt velje mellom, som er: stalk_root, odor, bruises, spore_print_color, stalk_surface_below, cap_surface, cap_shape, ring_number og gill_size. Etter brukaren har teke vala sine, vert vala samla i eit format som samsvarar med dataa modellen vart trena på. Den lagra ml-modellen handsamar verdiane gjennom den same førehandshandsaminga som vart teke i bruk under treninga, før han returnerer ei føreseiing om klassen. Til slutt vis nettsida resultatet for brukaren, på botn.



Nettsida gjer det mogleg for brukaren å prøve modellen utan å måtte køyre Python-kode sjølv. Modellen kan likevel ta feil, og resultatet må ikkje nyttast som grunnlag for å avgjere om ein sopp er trygg å ete.
For å halde systemet ved like bør ein kontrollere at nettsida og modellen fungerer som dei skal, og at dataa som vert sende inn, vert handsama rett. Dersom modellen seinare skal nyttast på eit større utval av soppar, bør han testast på nye data. Ein kan òg utvikle systemet vidare ved å gjere brukargrensesnittet tydelegare eller undersøkje om ein modell trena på fleire data kan gje betre resultat.

5: REFERANSAR

AI for læring og hjelp med feilsøking
Géron, A. (2023). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems (3rd ed.). O'Reilly Media.
Mushroom [Dataset]. (1981). UCI Machine Learning Repository. https://doi.org/10.24432/C5959T.